Appunti sul progetto ASSD (Analisi del server Unisannio)

Strumenti utilizzati

Probe (sorgente dei dati)

Bisogna misurare potenza, temperature e raffreddamento del server.

Strumenti: sensori **iLO** del DL380A, esposti su http://192.168.240.225:1880/metrics.

iLO: Integrated Lights-Out.

Il significato del nome si divide in due parti:

- **Integrated (Integrato)**: Il chip di gestione è saldato direttamente sulla scheda madre del server.
- **Lights-Out (A luci spente)**: È un termine informatico che fa riferimento ai data center automatizzati (chiamati appunto "lights-out data centers"), pensati per funzionare in totale autonomia senza la necessità di personale umano presente fisicamente nella stanza.

Perché si è usato questo:

- sono sensori hardware reali: niente stime, altrimenti potrebbero **sovrastimare** il consumo CPU;
- coprono potenza degli alimentatori, CPU, ΔT (differenza di temperatura) e unità di raffreddamento a liquido LCP, con ventole e compressore;

Limite: risoluzione di 1 W; assenza di dati sul ciclo di vita dell'hardware (termine M dello SCI).

Database time-series

Bisogna raccogliere campioni periodici e interrogarli per finestre temporali.

Strumento: Prometheus, scraping (**interroga periodicamente l’endpoint /metrics**) ogni 15 s.

Perché si è usato questo:

- modello **pull**: va a leggere l'endpoint iLO esistente senza alcuna modifica al server;
- progettato per serie temporali;
- integrazione nativa con Grafana;

Trade-off sull'intervallo (15 s):

- più piccolo → più risoluzione, più carico e spazio;
- più grande → eventi brevi mediati.

15 secondi è un compromesso che impone la regola dei test **≥ 3-5 minuti** (12-20 campioni).

Visualizzazione

Bisogna esplorare in tempo reale potenza, temperature e raffreddamento del server.

Strumento: Grafana, con datasource Prometheus.

Perché si è usato questo:

- dashboard interattive e filtri temporali;
- la dashboard è un JSON versionabile (indica qualcosa che può essere sottoposto a versionamento, ovvero di cui si possono creare, tracciare e gestire diverse versioni nel tempo) nel repo.

Layer API

Bisogna esporre "la nostra vista sul sistema, non il grezzo di Prometheus".

Strumento: FastAPI.

Perché si è usato questo:

- contiene la **logica di dominio**: integrazione dell'energia, separazione CPU / altri componenti;
- validazione automatica dei parametri (es. format ammesso solo json o csv);
- Python è lo stesso linguaggio dei test AI, quindi dati direttamente utilizzabili in script.

Due endpoint, due scopi:

- `/summary`: aggregato su una finestra (energia, medie);
- `/timeseries`: serie a 15 s in JSON o **CSV** per analisi statistiche in Python.

Orchestrazione

Bisogna far partire tutto in modo uguale per tutti.

Strumento: Docker Compose.

Perché si è usato questo:

- isolamento delle dipendenze;
- configurazione dichiarativa e versionabile;
- rete interna con risoluzione per nome (http://prometheus:9090).

Trade-off: piccolo overhead di virtualizzazione, da dichiarare perché rientra nel software boundary.

Accesso alla rete (VPN)

Bisogna raggiungere i sensori iLO e la VM di test, che si trovano in una rete privata dell'università.

Strumento: VPN (OpenVPN), con i file di configurazione dati dall'unisannio.

Perché si è usato questo:

- l’endpoint http://192.168.240.225:1880/metrics e la VM (`172.31.2.150`) sono raggiungibili solo dall’interno della rete;
- l’accesso è limitato a chi ha le credenziali, senza aprire porte pubbliche sul server;
- non richiede modifiche al server né software aggiuntivo su di esso.

Limite: dipendenza da un componente esterno; una caduta della VPN interrompe la raccolta; la VPN è un prerequisito per ogni misura: va connessa prima di avviare lo stack e per tutta la durata del test.

Limiti delle scelte

1. Il monitoraggio consuma energia (software boundary).
2. Scraping a 15 s: eventi brevi mediati.
3. Prometheus non è adatto ad analisi statistiche pesanti (si usa il CSV).
4. Dipendenza dalla VPN: la raccolta dei dati si può interrompere se la VPN cade.

Ogni strumento risponde a un requisito preciso: **iLO** perché dà misure reali senza installare software aggiuntivo sul server, **Prometheus** perché legge quell'endpoint così com'è, **Grafana** per le dashboard interattive, **FastAPI** per esporre una vista aggregata con lo SCI, **Docker Compose** per rendere tutto riproducibile, la **VPN OpenVPN** per raggiungere la rete privata in cui si trovano iLO e VM.

Analisi della baseline

Misurare quanto consuma un carico AI sembra semplice. In realtà il valore letto durante il test non dice quanto consuma l’AI, perché un server acceso assorbe energia anche senza fare nulla: alimentatori, ventole, RAM, dischi, schede di rete e CPU in idle lavorano comunque. Se si guardasse solo la potenza durante il test, si attribuirebbe all’AI anche il consumo che il server avrebbe avuto lo stesso.

Per questo l'analisi si fa in due passi, con le stesse regole (stessa durata, stesso campionamento a 15 s, stesso server). Prima la **baseline**: si misura il server a macchina scarica e si ottiene il consumo di base. Poi il **carico AI**: si lancia l'inferenza e si misura di nuovo. La differenza tra le due misure è il contributo del carico, cioè la parte di consumo realmente dovuta all'AI.

Questa sezione descrive la baseline; la sezione successiva il confronto con il carico AI.

Lo script di misura (`run_test.py`)

Lo script non misura nulla da solo: decide **quando** inizia e finisce la finestra e poi chiede all'API di calcolare tutto sui campioni che Prometheus ha già raccolto in background.

Blocco	Cosa fa
`import json, requests, time`	`time` per attese e timestamp, `requests` per chiamare l'API, `json` per salvare il riepilogo
`API_URL`	indirizzo del container `telemetry-api` su localhost:8000
`TEST_NAME`	dà il nome ai file di output
`FUNCTIONAL_UNITS_R`	parametro R dello SCI; per l'idle vale 1 perché non c'è un'unità di lavoro
`DURATA`	lunghezza della finestra in secondi (300 = 5 min)
`time.sleep(15)`	attesa di un ciclo di scraping, così la finestra parte su dati freschi
`start_ts = time.time()`	inizio finestra, in secondi UNIX con decimali (parametro `start`)
`time.sleep(DURATA)`	per l'idle non si fa nulla: Prometheus continua a campionare ogni 15 s.
`end_ts = time.time()`	fine finestra (parametro `end`); i due timestamp vengono stampati per poter richiamare l'API a mano con gli stessi valori
`GET /summary`	l'API interroga Prometheus e restituisce energia, medie, temperatura e SCI sulla finestra;
`json.dump(..., indent=4)`	salva `summary_idle.json` in forma leggibile
`GET /timeseries` con `format=csv`	restituisce la tabella a passo 15 s; si usa `.text` perché è testo, non JSON
ultima `print`	mostra lo SCI; `.get()` con default `{}` evita crash se l'API risponde con un errore

Obiettivo e metodo

Misurare il server **a riposo** (nessun carico AI lanciato) per avere il riferimento contro cui confrontare il test AI.

- Sorgente: sensori iLO, letti da Prometheus ogni T_S = 15 s.
- Intervalli: N = **Δ** t/T_S = 300/15 =20, quindi **21 righe** nel CSV (si contano entrambi gli estremi).
- Output: i dati grezzi sono salvati in timeseries_idle.csv (21 campioni a passo 15 s, tutte le metriche) e summary_idle.json (riepilogo calcolato dall'API: medie, energia, SCI).

Le metriche misurate

Metrica	Unità	Significato	Media idle
`total_power_w`	W (watt)	potenza totale del server (somma degli alimentatori)	**303,85**
`cpu_power_w`	W	quota dovuta ai processori	52,3
`cpu_util_pct`	% (percentuale)	tempo di occupazione della CPU	11,7 (max 13)
`mem_bus_util_pct`	%	traffico CPU-RAM rispetto al massimo	4,2
`cpu_freq_mhz`	MHz (megahertz)	frequenza operativa (DVFS)	392,75
`delta_t_celsius`	°C (gradi centigradi)	salto termico associato allo smaltimento del calore	6,3
`lcp_fans_rpm`	giri/min	velocità ventole dell'unità di raffreddamento a liquido	1702
`lcp_compressor_a`	A (ampere)	corrente del compressore dell'LCP	4,3

Raggruppate: **energia** (potenza totale e CPU), **calcolo** (utilizzo, bus memoria, frequenza), **temperatura** (ΔT), **raffreddamento** (ventole, compressore).

Formule usate

Potenza media

$\bar{P} = (1/n) \cdot \Sigma P_i$ (la sommatoria va da 1 a n).

Con i campioni del CSV: $\bar{P}_{CPU} = 52{,}3$ W e $\bar{P}_{tot} = 303{,}85$ W.

Potenza degli altri componenti

$P_{altri} = P_{tot} - P_{CPU} = 303{,}85 - 52{,}3 = 251{,}55$ W

Non è il totale a riposo: il totale è ~304 W.

Energia

$E\ (Wh) = \bar{P} \cdot \Delta t\ /\ 3600$

(1 Wh = 3600 J).

Componente	Calcolo	Risultato
Totale	$303{,}85 \cdot 300\ /\ 3600$	25,32 Wh
CPU	$52{,}3 \cdot 300\ /\ 3600$	4,358 Wh
Altri	$251{,}55 \cdot 300\ /\ 3600$	20,96 Wh

SCI (Software Carbon Intensity)

$SCI = (E \cdot I + M)\ /\ R$

- E: energia in kWh
- I: intensità carbonica della rete (gCO_2eq/kWh) (grammi di anidride carbonica equivalente per chilovattora)
- M: emissioni incorporate dell'hardware
- R: unità funzionale

Calcolo:

$E = 25{,}3208 / 1000 = 0{,}025321\ \text{kWh}$

$O = E \cdot I = 0{,}025321 \cdot 250 = 6{,}330\ \text{gCO}_2\text{eq}$

$\text{SCI}_{\text{idle}} = (6{,}330 + 0) / 1 = 6{,}330\ \text{gCO}_2\text{eq}$

con I = 250 (media fissa in Italia), M escluso (l'iLO non espone dati sul ciclo di vita) e R = 1.

Attenzione: per l'idle questo valore **non ha significato reale**, perché non esiste un'unità funzionale per un server a riposo. Serve solo come riferimento numerico.

Cosa dice la baseline

1. **Il server non è mai a zero.** A riposo assorbe ~304 W: il **baseload** (alimentatori, ventole, RAM, dischi, schede, CPU idle).
2. **Il consumo sembra poco proporzionale al carico (da verificare col test AI).**
3. **Peso della CPU:** $52{,}3 / 303{,}85 \approx 17{,}2\ \%$ del totale; il restante ~82,8 % è non-CPU.
4. **Stabilità:** potenza compresa tra 300 e 308 W, senza picchi.
5. **Raffreddamento costante:** ΔT (6,3 °C), ventole (1702 RPM) e compressore (4,3 A) sono costanti in tutti i 21 campioni. ΔT e raffreddamento non seguono la potenza del server e dipendono da fattori non controllati (ambiente, altri carichi sull'unità LCP).

Limiti

1. M escluso: dati non esposti dall'iLO.
2. I fisso a 250 gCO_2eq/kWh: media nazionale, non in tempo reale.
3. Campionamento a 15 s: eventi brevi mediati.
4. Potenza con risoluzione di 1 W.
5. CPU a ~12 % in idle: carico di fondo, forse di altri utenti sul server condiviso.

6. Frequenza CPU media di 386 MHz anomala per un server: probabile DVFS o unità non omogenea, non va interpretata alla lettera.

A riposo il DL380A assorbe **~304 W** (≈ 252 W non-CPU e ≈ 52 W CPU), con consumo di 25,32 Wh in 300 s: è il riferimento P_{idle} da sottrarre al test AI per isolare il contributo del carico.

Analisi del carico AI

Scelta dei modelli e obiettivo delle prove

L'analisi del **carico AI** è stata condotta per valutare l'impatto dell'esecuzione di modelli di **elaborazione del linguaggio naturale (NLP)** sui consumi energetici del server DL380a. In particolare, i risultati ottenuti durante l'inferenza sono stati confrontati con una condizione di riferimento, denominata *idle*, nella quale non viene eseguito il carico AI previsto dalla prova, pur rimanendo attive le normali funzionalità del server.

Sono stati scelti tre modelli con dimensioni e caratteristiche computazionali differenti: **DistilBERT, BERT-base e RoBERTa-large**. DistilBERT è una versione più compatta di BERT, progettata per ridurre il costo computazionale; BERT-base rappresenta un modello di dimensioni intermedie, mentre RoBERTa-large consente di valutare il comportamento del sistema con un modello più grande e complesso. Il confronto tra questi modelli permette di esaminare se un aumento della complessità del modello corrisponda a un maggiore consumo energetico e come si modifichino l'utilizzo delle risorse hardware e i parametri termici del server.

Procedura sperimentale

La campagna di misurazione è stata articolata in quattro prove: una **baseline in condizioni di idle** e tre prove, una per ciascun modello AI. Ogni misurazione ha avuto una durata di **300 secondi**, equivalenti a cinque

minuti, in modo da rendere confrontabili i consumi rilevati nelle diverse condizioni.

Prima dell'inizio di ogni prova è stato previsto un intervallo di attesa di 15 secondi per consentire al sistema di monitoraggio di acquisire un nuovo campione. Lo script di test ha quindi registrato l'istante iniziale, atteso per 300 secondi e acquisito l'istante finale. Al termine della misurazione sono stati recuperati i dati aggregati relativi all'intervallo temporale considerato e la **serie temporale dei parametri monitorati**, esportata in formato CSV.

Il sistema di monitoraggio acquisisce i dati ogni **15 secondi**. In una finestra di cinque minuti sono pertanto presenti circa 20 intervalli di campionamento; il numero di campioni registrati può arrivare a 21 quando la serie comprende sia l'istante iniziale sia quello finale. L'analisi ha considerato la **potenza totale**, la potenza attribuita alla CPU, il contributo degli altri componenti, l'utilizzo medio e massimo del processore, l'utilizzo del bus di memoria, la frequenza media riportata e alcuni indicatori relativi al raffreddamento.

Analisi della potenza e dell'energia

L'osservazione delle serie temporali della potenza totale permette di distinguere il comportamento del server in idle da quello durante l'esecuzione dei modelli AI. Nella baseline, la potenza media complessiva è risultata pari a 303,85 W. Durante le prove con i modelli, invece, i valori medi sono aumentati, raggiungendo **328,75 W con DistilBERT, 331,20 W con BERT-base e 331,80 W con RoBERTa-large**.

Parametro	Idle	DistilBERT	BERT-base	RoBERTa-large
Potenza media totale (W)	303,85	328,75	331,20	331,80
Incremento rispetto all'idle (W)	—	24,90	27,35	27,95
Incremento rispetto all'idle (%)	—	8,19%	9,00%	9,20%
Energia consumata in 300 s (Wh)	25,32	27,39	27,60	27,65
Energia aggiuntiva rispetto all'idle (Wh)	—	2,07	2,27	2,32

L’incremento percentuale della potenza media è stato calcolato confrontando la differenza tra la potenza misurata durante il test e quella della baseline con il valore di riferimento dell’idle. In questo modo, l’aumento risulta pari all’8,19% per DistilBERT, al 9,00% per BERT-base e al 9,20% per RoBERTa-large.

$$\Delta P_{\%} = (P_{\text{modello}} - P_{\text{idle}}) / P_{\text{idle}} \cdot 100$$

I risultati mostrano che l’esecuzione dei modelli comporta un aumento della potenza assorbita dal server, ma che tale incremento rimane relativamente contenuto rispetto al consumo già presente in condizioni di idle. La differenza tra DistilBERT e RoBERTa-large è di 3,05 W in termini di potenza media, mentre tra BERT-base e RoBERTa-large è di appena 0,60 W. I tre modelli presentano quindi **assorbimenti complessivi abbastanza simili**, nonostante le differenze nelle loro dimensioni.

Anche l’energia consumata durante i cinque minuti di prova conferma questa tendenza. La baseline ha registrato 25,32 Wh, rispetto ai 27,39 Wh di DistilBERT, ai 27,60 Wh di BERT-base e ai 27,65 Wh di RoBERTa-large. Per stimare l’energia aggiuntiva associata al carico AI, è stata sottratta l’energia della baseline da quella totale misurata durante ciascuna prova. Si ottengono così 2,07 Wh per DistilBERT, 2,27 Wh per BERT-base e 2,32 Wh per RoBERTa-large.

$$\Delta E = E_{\text{modello}} - E_{\text{idle}}$$

Questa differenza rappresenta una **stima dell’energia aggiuntiva rispetto all’idle**, assumendo condizioni operative comparabili; non corrisponde al consumo isolato del solo modello, perché la potenza misurata comprende anche gli altri componenti del server. I valori devono inoltre essere confrontati su finestre temporali equivalenti: il consumo complessivo di 74,4 Wh mostrato dalla dashboard su un intervallo di 15 minuti, ad esempio, non è direttamente confrontabile con i dati delle singole prove di cinque minuti.

Utilizzo delle risorse computazionali

Le metriche di utilizzo della CPU e del bus di memoria confermano che l'esecuzione dei modelli AI determina un **aumento dell'attività computazionale** rispetto alla baseline.

Parametro	Idle	DistilBERT	BERT-base	RoBERTa-large
Utilizzo medio CPU (%)	11,70	19,65	20,10	20,35
Utilizzo massimo CPU (%)	13,00	22,00	23,00	23,00
Utilizzo medio bus di memoria (%)	4,20	12,50	13,05	13,15
Frequenza CPU media riportata (MHz)	392,75	487,40	520,20	545,05
Potenza media CPU (W)	52,30	56,40	57,40	58,20

L'utilizzo medio della CPU passa dall'**11,70% della baseline al 19,65% con DistilBERT, al 20,10% con BERT-base e al 20,35% con RoBERTa-large**. Anche la potenza media attribuita al processore aumenta, passando da 52,30 W in idle a 56,40 W, 57,40 W e 58,20 W rispettivamente.

Un andamento analogo si osserva per il bus di memoria: il suo utilizzo medio cresce dal **4,20% della baseline** a valori compresi tra il 12,50% e il 13,15% durante i test AI. Questo comportamento è coerente con la maggiore attività richiesta dall'elaborazione dei dati durante l'inferenza. Tuttavia, l'utilizzo medio della CPU rimane intorno al 20%, indicando che, nelle condizioni sperimentali considerate, il carico rilevato non porta a un utilizzo medio elevato della capacità complessiva del processore. Tale dato, da solo, non permette comunque di stabilire se il modello sfrutti in modo ottimale tutte le risorse disponibili.

La frequenza media riportata aumenta da 392,75 MHz in idle a 545,05 MHz con RoBERTa-large. Prima di interpretare quantitativamente questa variazione, è necessario verificare la definizione della metrica e l'unità di misura esposta dal sistema di monitoraggio.

Nel complesso, i dati indicano che il carico AI aumenta l'attività del processore e del sottosistema di memoria. La variazione della potenza totale è però più contenuta rispetto a quella di alcune metriche di utilizzo,

poiché il consumo complessivo comprende anche l'assorbimento degli altri componenti hardware.

Comportamento termico e raffreddamento

Oltre alle metriche energetiche e computazionali, sono stati analizzati alcuni parametri relativi al **comportamento termico** e al sistema di raffreddamento.

Parametro	Idle	DistilBERT	BERT-base	RoBERTa-large
Differenziale di temperatura (°C)	6,3	5,3	5,3	5,3
Velocità delle ventole (RPM)	1702	1665	1665	1665
Corrente del compressore (A)	4,30	4,33	4,36	4,34

Il differenziale di temperatura medio passa dai **6,3 °C della baseline a 5,3 °C in tutte e tre le prove AI**. Anche la velocità delle ventole risulta leggermente inferiore, passando da 1702 RPM a 1665 RPM. La corrente del compressore rimane invece pressoché stabile, con valori compresi tra 4,33 A e 4,36 A durante i test.

Questi risultati non evidenziano un aumento dei parametri termici e di raffreddamento monitorati durante le prove AI. Non è tuttavia possibile attribuire con certezza le variazioni osservate a una causa specifica, poiché i dati disponibili non sono sufficienti per ricostruire nel dettaglio il comportamento del sistema di raffreddamento o le condizioni ambientali durante ogni misurazione.

Valutazione delle emissioni operative

Per stimare l'impatto ambientale legato all'energia consumata durante le prove è stata adottata un'**intensità carbonica pari a 250 gCO_2eq/kWh**. Le emissioni operative sono state calcolate moltiplicando l'energia consumata, espressa in kWh, per tale fattore. La stima riguarda le emissioni associate all'elettricità utilizzata e non include quelle incorporate nella produzione e nel ciclo di vita dell'hardware.

$C_{operativo} = E_{kWh} \cdot I$

Configurazione	Energia (kWh)	Emissioni operative (gCO_2eq)
Idle	0,025321	6,3302
DistilBERT	0,027396	6,8490
BERT-base	0,027600	6,9000
RoBERTa-large	0,027650	6,9125

Le emissioni operative complessive risultano pari a 6,8490 gCO_2eq per DistilBERT, 6,9000 gCO_2eq per BERT-base e 6,9125 gCO_2eq per RoBERTa-large. Questi valori includono il consumo di base del server e seguono quindi lo stesso andamento dell'energia totale misurata.

Considerando invece la sola differenza rispetto alla baseline, le emissioni aggiuntive stimate sono circa 0,519 gCO_2eq per DistilBERT, 0,570 gCO_2eq per BERT-base e 0,582 gCO_2eq per RoBERTa-large nell'arco dei cinque minuti. Questa seconda prospettiva permette di isolare, in termini comparativi, l'incremento rispetto al funzionamento di riferimento, pur rimanendo una stima subordinata alla comparabilità delle condizioni operative.

Confronto in relazione al lavoro completato

Il confronto dei consumi totali non è sufficiente, da solo, per stabilire quale modello sia più efficiente nell'esecuzione del compito. È necessario considerare anche la quantità di lavoro completata durante la stessa finestra temporale. Nei dati disponibili, il numero di unità di lavoro registrate è pari a 3968 per DistilBERT, 1920 per BERT-base e 576 per RoBERTa-large.

$C_R = C_{operativo} / R$

Per valutare le emissioni operative per unità di lavoro, le emissioni complessive di ciascuna prova sono state rapportate al numero di unità completate. I risultati sono riportati di seguito.

Modello	Unità di lavoro	Emissioni totali per unità (gCO_2eq/unità)

DistilBERT	3968	0,0017
BERT-base	1920	0,0036
RoBERTa-large	576	0,0120

In base a questo indicatore, **DistilBERT presenta il valore più basso di emissioni per unità di lavoro**, seguito da BERT-base e RoBERTa-large. La differenza è legata anche al numero di unità completate nella finestra di cinque minuti: DistilBERT ne registra molte più di RoBERTa-large, mentre i consumi energetici complessivi dei due test risultano relativamente vicini.

Questo confronto è significativo solo se l'unità di lavoro è definita in modo omogeneo per tutti i modelli. Se il conteggio corrisponde al numero di inferenze, è necessario che queste siano confrontabili per tipologia di operazione e caratteristiche degli input. Inoltre, i valori riportati includono il consumo di base del server. Per valutare esclusivamente le emissioni aggiuntive rispetto all'idle per unità di lavoro, occorre utilizzare al numeratore la differenza tra le emissioni della prova e quelle della baseline.

Considerazioni conclusive

Le prove mostrano che l'esecuzione dei modelli AI aumenta la potenza media assorbita dal server rispetto alla condizione di idle, con incrementi compresi tra l'8,19% e il 9,20%. L'energia aggiuntiva stimata nell'arco di cinque minuti varia da **2,0750 Wh per DistilBERT a 2,3292 Wh per RoBERTa-large, mentre BERT-base si colloca su un valore intermedio**.

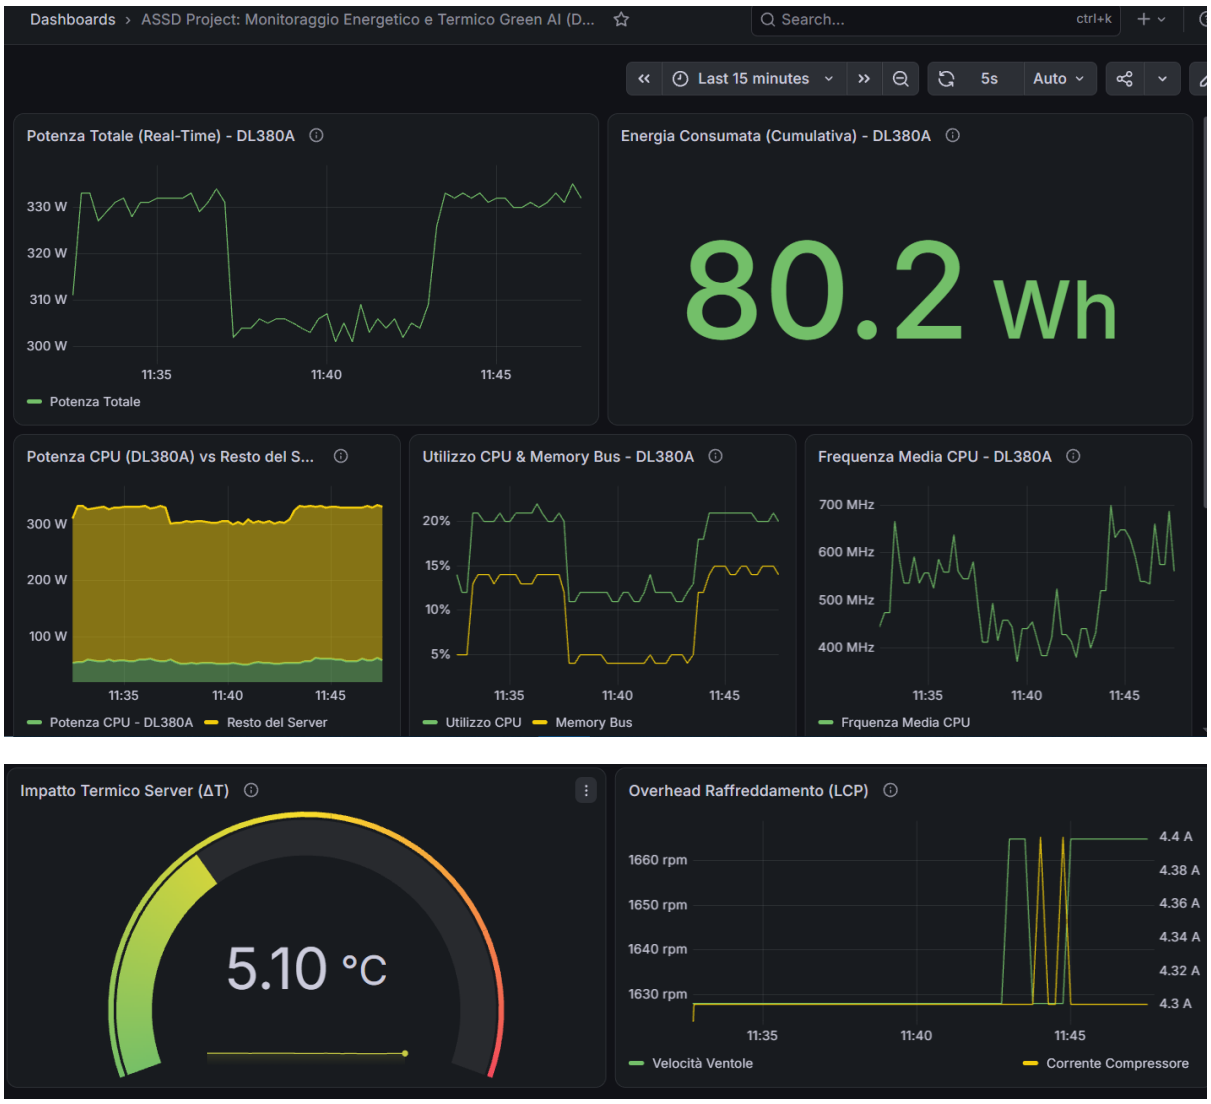
Le metriche di utilizzo confermano una maggiore attività della CPU e del bus di memoria durante l'inferenza, ma la potenza totale rimane relativamente simile tra i tre modelli. Questo risultato evidenzia l'importanza del **consumo di base del server** e mostra perché la sola potenza complessiva non sia sufficiente per confrontare l'efficienza dei modelli.

Anche le metriche termiche e di raffreddamento non mostrano differenze marcate tra le tre prove AI. Dal punto di vista ambientale, le emissioni operative totali sono vicine tra loro, mentre il confronto per unità di lavoro

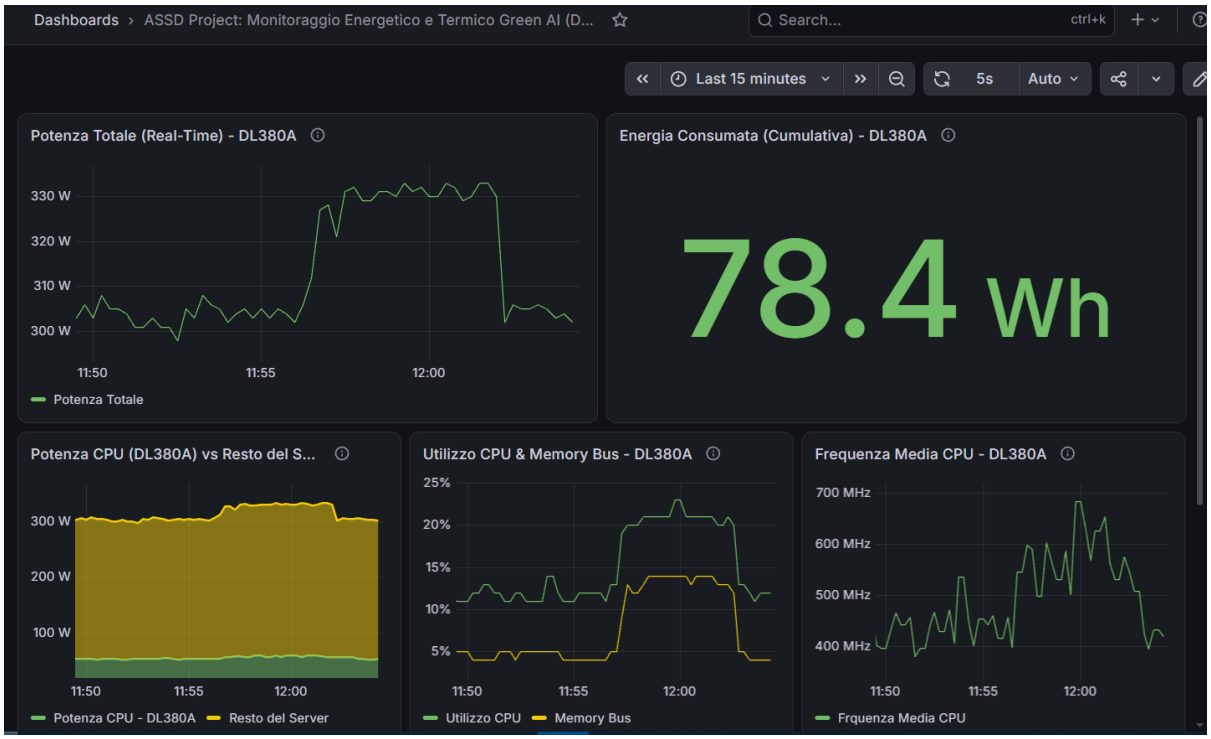
evidenzia differenze più ampie. Quest'ultimo risultato deve comunque essere interpretato alla luce della definizione e della comparabilità delle unità completate.

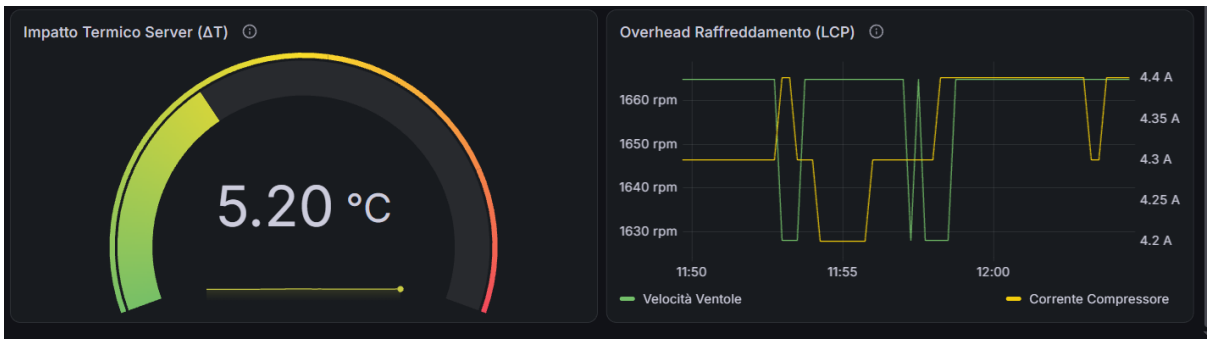
Nel complesso, nelle condizioni sperimentali analizzate, **DistilBERT presenta il minore incremento di potenza e il valore più basso di emissioni operative per unità di lavoro; RoBERTa-large presenta invece i valori più elevati**. Questi risultati sono riferiti alle specifiche prove di cinque minuti e non possono essere generalizzati automaticamente a carichi, configurazioni o modalità di inferenza differenti.

Analisi DistilBERT e Base_BERT - Grafana



Analisi RoBERTa - Grafana


Dashboards › ASSD Project: Monitoraggio Energetico e Termico Green AI (D...
Search...
ctrl+k
Last 15 minutes
5s
Auto
Potenza Totale (Real-Time) - DL380A
330 W
320 W
310 W
300 W
11:50
11:55
12:00
Potenza Totale
Energia Consumata (Cumulativa) - DL380A
78.4 Wh
Potenza CPU (DL380A) vs Resto del S...
300 W
200 W
100 W
11:50
11:55
12:00
Potenza CPU - DL380A
Resto del Server
Utilizzo CPU & Memory Bus - DL380A
25%
20%
15%
10%
5%
11:50
11:55
12:00
Utilizzo CPU
Memory Bus
Frequenza Media CPU - DL380A
700 MHz
600 MHz
500 MHz
400 MHz
11:50
11:55
12:00
Frquenza Media CPU


Impatto Termico Server (ΔT)
5.20 °C
Overhead Raffreddamento (LCP)
1660 rpm
1650 rpm
1640 rpm
1630 rpm
4.4 A
4.35 A
4.3 A
4.25 A
4.2 A
11:50
11:55
12:00
Velocità Ventole
Corrente Compressore